

LLM Agent 驱动的论文数值复现

以电磁多极展开 (mie-f) 四轮复现为例

张元正

2026-08-14

► 报告定位：本文面向 LLM / agent 方向读者，总结我如何用多 agent 编排完成四篇电磁多极展开经典论文的数值复现。侧重 **agent** 架构、工作流、记忆治理、验证方法论与经验沉淀，
不展开电磁学物理本身（物理推导与验证数字见另两份给光学组的报告）。

目录

1	项目概览	3
1.1	复现对象	3
1.2	四轮复现与结果	3
1.3	本报告关注的维度	3
2	Agent 架构与分工	3
2.1	三层分工	4
2.2	核心纪律：判断密度路由	4
2.3	子 agent 并发 (fan-out)	4
2.4	codex 后台委托 (并发 + 长任务)	4
3	复现工作流	5
3.1	多轮 × 7 步循环	5
3.2	4 个人工 gate (agent 自由跑, gate 必须停)	5
3.3	复述纪律 (防转述漂移)	5
3.4	人工复核硬化	5
3.5	关键节点必须停	5
4	记忆与知识管理	6
4.1	memento: 语义检索的长期记忆	6
4.2	MEMORY.md: 恢复上下文的索引头	6
4.3	doc-sync: 面向用户的设计同步	6
4.4	skill: 从经验到可复用指令	6
5	验证方法论	7
5.1	formalization: 把论文声明规格化	7
5.2	物理验证三元组	7

5.3	预注册：先冻结 spec 再跑	7
5.4	result_class 诚实标注	7
6	读图处理与人工复核	8
6.1	为什么读图是最大隐性错误源	8
6.2	刻度/坐标轴铁律	8
6.3	log / linear 判定	8
6.4	读图数据 vs 解析解的取舍	8
7	挑战、教训与 skill 沉淀	9
7.1	踩过的主要坑	9
7.2	从经验到 skill: 10 个可复用 skill	9
7.3	skill 提炼原则：泛化而非复制	9
8	结论与可复用性	10
8.1	这套方法沉淀了什么	10
8.2	关键数字一览	10
8.3	迁移价值	10

1 项目概览

1.1 复现对象

本项目复现四篇电磁多极展开（multipole expansion）方向的经典论文，形成一条从「多极映射」到「精确多极矩」的理论链：

论文	内容	复现目标
Grahn 2012 (NJP 14 093033)	电磁多极理论映射	电流矩 $\rightarrow$ 电/磁多极系数的映射关系
FC2015 (Opt. Express 23 33044)	精确偶极矩	精确电偶极矩定义与退化
FC2017 (Sci. Rep. 7 7527)	toroidal 多极非独立	toroidal 不是独立自由度的严格证明
Alaee 2018 (Opt. Commun. 407 17)	超越长波近似	Table 1（长波）vs Table 2（精确）多极矩

1.2 四轮复现与结果

按「一轮复现一张图 / 一个结论」组织为四轮，每轮独立验收：

轮	对象	方法	结果
1	Fig.1 介电球散射截面	Mie 解析 + Table 2 积分	双实现交叉 $< 0.21\%$
2	Fig.2 金球多极分解	同上（加密网格）	双实现交叉 $< 0.03\%$
3	Grahn 映射	双路径 + 独立远场	相对差 $5.7 \times 10^{-7} \sim 2.9 \times 10^{-4}$
4	Fig.3 双金盘 Fano	COMSOL FEM + BEM	两求解器交叉，网格收敛评估

► 要点

一个关键数字：双金盘（非球形、无解析解）用边界元法（BEM）128 GB 就跑通了同一几何，而有限元（FEM）频域直接求解器需要 900 GB——省约 7 倍。这说明 ** 选对数值方法比堆算力更重要 **。

1.3 本报告关注的维度

给光学组的报告讲「物理为什么对」（三条物理判据），本报告讲「agent 怎么把这件事做对」——即复现过程中 **agent 编排、记忆治理、验证方法论、读图处理、经验沉淀**这一整套工程方法。二者互补，物理报告回答「算对了吗」，本报告回答「这套 agent 工作流能不能复用」。

2 Agent 架构与分工

复现不是单模型从头做到尾，而是 ** 三层 agent 分工 **——每层有不同的职责、模型档位与上下文边界。

2.1 三层分工

层	职责	模型档位	上下文边界
主 agent	编排：读路线图、spawn 子 agent、汇总报告、在 gate 停顿问用户	主循环	保留判断层，不亲自做隔离活
子 agent	执行单步（formalization / 实现 / 验证…）	常规档	只读/写限定目录，报告回传结论
codex 后台委托	多模态读图、并发批量、长任务	难活用强模型	后台 bash 并发，产物落盘不占主 context

2.2 核心纪律：判断密度路由

一条贯穿始终的规则——**读文件内容不进主 context 的，都派子 agent**。主 agent 亲读大段文件/多文件会把原文灌进主 context，压缩信噪比。所以：

- 单事实查询（已知文件/符号）→ 直接 Grep/Read，不派 agent；
- 跨多文件调查、架构梳理 → 派只读子 agent，只收结论不收文件转储；
- 裁决必需的读（gate 停机点）→ 主 agent 亲读，不转述。

2.3 子 agent 并发（fan-out）

两张独立图 / 两个独立子任务可并发 spawn 多个子 agent，主 agent 是唯一汇聚点。**并发前提是真独立**——无数据/文件/逻辑依赖；有依赖就串行。

2.4 codex 后台委托（并发 + 长任务）

多模态读图、大批量、深推理的任务交给 codex 后台执行，特点是：

- **并发 = 多条后台 bash**，每条 `run_in_background`，互不阻塞，各自落盘；
- **长任务不设硬超时**——委托可能跑很久，硬超时会误杀接近完成的任务（踩过：codex 渲染完大部分产物却在收尾落盘时被超时 kill）；
- **判活看落盘产物**是否在增长（事件流尾部时间戳、result 文件是否出现），而非猜；
- **产物落盘传路径**，不靠 stdout（会截断），主 agent 亲读落盘产物做验收。

► 要点

这套三层分工的关键不是「用多个模型」，而是 **** 把「判断」和「执行」分离 ****：判断（gate 裁决、物理归因、方法选型）留在主循环，执行（写码、跑脚本、读图、批量）下沉到子 agent / 后台。这样主 context 始终只装「结论 + 关键定位」，而不是执行细节。

3 复现 workflow

3.1 多轮 × 7 步循环

每轮复现一张图/一个结论，轮内 7 步：

步 名	产出
01 PDF 预处理	从论文提取参数/公式/图数据
02 formalization	参数确认 + 机器可判 spec (YAML)
03 theory notes	公式来源、推导、与教材对标
04 implementation	代码 + 测试 (TDD, 物理约束先硬编码)
05 run & monitor	运行 + 收集数据
06 physical verification	3 层验证 (硬约束 → 极限 → 论文图量化)
07 analysis & report	归因 + 双报告 + 记忆

轮间共享公共模块 (特殊函数、基准解、多极矩)，每轮开头先读上一轮 worklog 决定复用 vs 新建。

3.2 4 个人工 gate (agent 自由跑, gate 必须停)

agent 可以自动推进，但四个节点必须停下来问用户，不代替人工裁决：

gate	触发点	用户核对什么
参数 gate	formalization 末	参数、单位、范围
spec gate	formalization 末	物理形式化与论文一致
公式 gate	实现/运行末	核心公式对权威教材核
误差 gate	报告末	量化误差数字，不接受「看起来一致」

3.3 复述纪律 (防转述漂移)

主 agent 向用户汇报任何「gate 裁决 / verifier 输出 / 已归档结论」的量化数值时，**必须现场重开原始文件核对**，不得凭对话历史记忆转述。数字、方向词、范围必须与原文逐字一致。这一条专门防「模型在长对话里凭印象转述已裁决数字，结果越传越偏」。

3.4 人工复核硬化

凡从论文图/位图提取的参数 (坐标轴类型、刻度值、峰位、曲线数据)，模型读数一律视为「未核实线索」：

1. 下一步开工前必须人工复核——formalization 定稿前用户亲自核对；
2. workflow 结束前整体复核一次——gate 前把所有「从图提取的参数」列清单，用户逐项复核再定稿 REPORT。

3.5 关键节点必须停

以下节点默认停 (除非用户说全自动)：进 REPORT 前、改 skill/蓝图前、物理验证失败要换方案时、遇到缺失信息时、**偏离既定 workflow 步骤时**。最后一条尤其重要——不得自主偏离后在

报告里事后声明代价，偏离前必须问用户。

4 记忆与知识管理

复现跨多轮、多会话，agent 需要四层记忆载体，各司其职、不混用：

载体	职责	时效	写入时机
memento	跨会话长期：事实/决策/坑，语义检索	永久，按 importance 分层	有实质产出/踩坑/决策时
MEMORY.md	恢复上下文：「我现在在哪、要做什么」	短时态，覆盖式更新	每工作单元结束 / compact 前
doc-sync	面向用户的设计现状 + 待决策	长期	新 agent 完成 / 新决策时
skill	可复用指令：经验沉淀为 SKILL.md	永久，跨场景	经验反复复现、用户拍板后

4.1 memento：语义检索的长期记忆

用「关键词 + 向量」融合排序，支持跨会话召回「三年前踩过的坑」。关键做法：

- 存完整句子而非碎片：内容越完整向量语义越准；
- importance 分层：决策 0.7+、日常 0.3–0.5，避免低价值记忆淹没搜索；
- 存前查重：用向量余弦相似度检查是否已有相似记忆；
- 结构化三工具：事实/决策走 memory_store，架构决策走 decisions_log，踩坑走 pitfalls_log。

4.2 MEMORY.md：恢复上下文的索引头

一个纯索引头文件（≤ 200 行），会话启动注入，回答「我现在在哪、当前在做什么」。只放索引，不放正文——发现、行为规范、任务细节全部下沉到 memory/ 目录的 topic 文件，头部只留指针。每次 compact 前覆盖式更新，不累积瞬时状态。

4.3 doc-sync：面向用户的设计同步

一套「主文档 + 副文档 + 待决策清单」系统，作为唯一 human 入口。用户只看 00-待决策清单就能拍板，其余读完即可。主文档多用 ASCII 图表示流程 + 状态表 + 跳转链接，副文档放每个设计 flow 的详细设计。

4.4 skill：从经验到可复用指令

复现结束后，把反复用到的经验提炼为 skill（本报告 §7 详述 10 个 skill）。核心原则是「泛化而非复制」——把项目专属的细节剥离，只保留可跨任务复用的编排/方法/铁律。

► 要点

四层载体的边界判据：需要语义召回 + 结构化 → memento；恢复「我在哪」→ MEM-

ORY.md; 给用户看现状与待决策 → doc-sync; 跨场景稳定复用 → skill。混用会各自失效——例如把「当前在做什么」塞进 `memento`，下次召回时反而找不到「长期结论」。

5 验证方法论

复现的落脚点不是「公式算对了」，而是「凭什么相信自己算对了」。这需要一套机器可判的验证方法。

5.1 formalization: 把论文声明规格化

第一步把论文的图/表/结论翻译成机器可判的 `YAML spec`——参数、单位、范围、验证判据全部显式写死。这是后续所有验证的契约：`agent` 对着 `spec` 跑，而不是对着「看起来像不像」跑。

5.2 物理验证三元组

三条相互独立的判据，任何一条不过都不放过：

1. 多近似方法对比（排除实现 bug）——同一物理对象用两条独立数学路径算，交叉比对。球体：Table 2 体积积分 vs Mie 级数求和；非球形无解析解：两种数值求解器互验（FEM vs BEM）。
2. 极限退化（排除公式抄错）——每个公式要求它在已知极限退化回已知结果。精确 Table 2 在 $kr \rightarrow 0$ 退化回长波 Table 1；Mie 退化回 Rayleigh x^4 ； $Q_{\text{ext}} \rightarrow 2$ 。多极矩系数由退化固定，不是照抄论文。
3. 能量守恒 / 光学定理（排除物理不自洽）—— $C_{\text{ext}} = C_{\text{sca}} + C_{\text{abs}}$ 到 10^{-10} ；光学定理 $S(0)$ 双路差 10^{-14} ；功率闭合 $\text{balance} = 1.0$ 。

三条叠加排除「实现 bug」「公式抄错」「物理不自洽」三类错误。

5.3 预注册：先冻结 spec 再跑

验证阈值（如 RMSE 0.020、p95 0.050）**必须在看到结果前冻结**，防「看到结果后调阈值抹平差异」这种事后发明。这是典型的科学诚信失败模式，`agent` 尤其容易踩——所以要显式预注册。

5.4 result_class 诚实标注

结果用 7 级枚举标注，禁把「跑通了管道」当「复现成功」：

等级	含义
<code>physical_reproduction_success</code>	物理复现成功
<code>partial_physical_match</code>	部分物理吻合（缺网格收敛/远场闭合等）
<code>surrogate_fallback</code>	替代方案（如读图数据）
<code>diagnostic_only</code>	仅诊断性结果
<code>pipeline_completed</code>	管道跑通，但物理未验证
<code>not_run / failed</code>	未运行 / 失败

读图数据永远是 `surrogate_fallback`，不是物理复现。「跑通了管道」（`pipeline_completed`）物理结论成立。

6 读图处理与人工复核

6.1 为什么读图是最大隐性错误源

复现论文离不开从图里读参数（坐标轴类型、刻度值、峰位、曲线数据）。但模型读图极不可靠——模型看同一张图两次可能给不同答案。

► 教训

最典型的一次：Fig.1 的 y 轴被模型判为 log 坐标，实际是 linear（刻度 1,3,5,7）。这个误判让整轮结论报废，最后被 vision-mcp 4 个通道交叉（2 个裁剪图 + 整图独立读）推翻。教训：任何单通道读数（包括主 agent 亲看原图）都可能错。

6.2 刻度/坐标轴铁律

从论文图提取任何参数时，必须遵守：

1. 用权威最高分辨率原图，不用低清 OCR 渲染、不用缩略图；
2. **vision-mcp 多通道收敛**：≥ 2 裁剪图 + 整图独立读，全一致才可信；
3. **轴标题 vs 刻度分离**：竖排英文轴标题（如 $C_{sca}/(\lambda^2/2\pi)$ ）是文字不是刻度，先剥离标题区域，否则竖排笔画混入被误判为刻度线；
4. 读到的值标 confidence + 提取方法 + 「未核实线索，待人工复核」。

6.3 log / linear 判定

不凭直觉判 log/linear。判定信号：刻度间距是否等距（linear 等距，log 每十倍等距）、轴标签是否含 10 的幂、网格线分布。多通道读同一根轴全一致才算定论，不一致就标「未核实，待复核」，不硬选一个继续算。

6.4 读图数据 vs 解析解的取舍

纯理论论文（曲线 = 标准解析解，如 Alae 2018 的曲线就是标准 Mie）没有作者原始数据可对齐，直接自己算解析解，读图数据放弃，人工目视相似即可。读图数据只用于峰位/形态定性比对，不用于精确数值标定——它永远是 `surrogate_fallback`。

7 挑战、教训与 skill 沉淀

7.1 踩过的主要坑

坑	教训
codex 反复被杀	服务端过载时后台任务被中断；resume 对多 agent 子会话不可用，只能 fork 重发；单任务连断多次 = 停发等窗口
长任务硬超时	委托接近完成时被超时 kill；改为不设超时，靠结束唤醒 + 落盘产物判活
读图误判	log/linear 误判毁掉整轮；必须 vision-mcp 多通道收敛 + 人工复核
BEM 调试 15 轮	接口不熟导致反复试错；核心坑：色散金属域 BEM 不支持、表面网格 selection 维度、远场需 FarFieldCalculation
内存估算	FEM 直接求解器 $O(\text{DOF}^{1.5})$ ，0.3 网格需 900G；先估 DOF 再申请资源
上下文膨胀	主 agent 亲读大文件撑爆 context；判断密度路由，读文件不进主 context 的派子 agent

7.2 从经验到 skill：10 个可复用 skill

复现结束后，把反复用到的经验提炼为 skill。共沉淀 **10 个**——其中 6 个从本项目直接提炼，4 个是过程中用到的通用能力：

skill	内容
paper-reproduction	复现编排：多轮 $\times 7$ 步 + 4 gate + 复述纪律 + 人工复核
figure-reading	读图提取：刻度铁律 + 多通道收敛 + 数字化
comsol-scattering	COMSOL FEM/BEM 建模 + 多极矩后处理 + 网格收敛
magnus-submit	集群 blueprint 提交 + 资源声明 + 红线
numeric-verification	物理验证三元组 + Richardson + result_class
third-party-cross-validation	第三方交叉验证 + 诚实区分同/异对象
adversarial-review	对抗性审查（独立视角审代码/结论）
transition-wrapup	会话收尾（整理 memento/MEMORY/rules）
doc-sync	设计文档同步（面向用户的现状 + 待决策）
grill-me	追问（对 agent 结论追问拍板）

7.3 skill 提炼原则：泛化而非复制

把一个项目专属的经验变成 skill，关键动作是**剥离专属细节、保留可复用骨架**：

- 项目内的 agent-workflow（写死「4 轮、Alaee Fig.1/2/3」）→ 泛化为 paper-reproduction（「多轮、任意论文」）；
- 散在多个 skill 里的「刻度铁律」→ 收口成独立的 figure-reading（单一权威来源）；
- 物理细节（Mie 公式、具体参数）不进 skill，留在各轮自己的 formalization/。

► 要点

skill 的边界判断:「脱离本项目,这件事能否独立成立为一个可复用任务?」能 → 独立 skill; 不能(只是某项目的局部步骤) → 留在项目内。避免把「我们做过 X」都堆成 skill——碎片化的 skill 比没有更糟。

8 结论与可复用性

8.1 这套方法沉淀了什么

四轮复现沉淀了一套 **agent** 驱动的科学计算方法论,核心是五个可复用组件:

1. 三层 **agent** 分工——判断与执行分离,主 context 只装结论;
2. **gate** + 复述纪律 + 人工复核——把「可信」交给机器可判的契约 + 人工停点,不交给模型自觉;
3. 四层记忆载体——memento / MEMORY.md / doc-sync / skill 各司其职;
4. 物理验证三元组 + **result_class**——回答「凭什么相信算对了」并诚实标注完成度;
5. **skill** 沉淀——10 个可复用 skill,经验不随会话消失。

8.2 关键数字一览

指标	值
复现论文	4 篇, 4 轮
球体双实现交叉	$< 0.21\%$ (介电) / $< 0.03\%$ (金)
Grahn 映射相对差	$5.7 \times 10^{-7} \sim 2.9 \times 10^{-4}$
能量守恒	到 10^{-10}
光学定理双路差	10^{-14}
BEM vs FEM 内存	128G vs 900G (省 7 倍)
沉淀 skill	10 个

8.3 迁移价值

这套方法不限于电磁散射,对任何「有解析基准可校验、有数值可交叉」的科学计算复现都成立:

- 有解析解的(球体/Mie 类) → 双实现交叉 + 极限退化,解析解就是验金石;
- 无解析解的(非球形/数值类) → 先球体校验求解器,再两数值方法互验 + 网格收敛;
- 无论哪类, **formalization** 规格化 + 三元组 + **result_class** 诚实都是通用底座。

► 要点

一句话总结:复现的可信度不是「看起来像」,而是「机器可判的契约 + 相互独立的物理判据 + 诚实标注的完成度」。agent 的价值在于把这三件事制度化、可复用,而不是替人「画一张像的图」。